

Tabular RL

回报、价值、策略与学习目标

苏骏炜 (Junwei Su)

课程路线与学习问题

01-02	交互、价值表与 Bandit	怎样估计期望，并兼顾探索？
03-04	MDP、价值、Bellman 与 DP	评价谁？状态概括什么？怎样改善策略？
05-06	Monte Carlo 与 TD	目标用完整回报，还是一片奖励加估计？
07	Sarsa 与 Q-learning	后续按当前策略，还是按最优行为评价？
08	多步学习与资格迹	怎样组合更多经验与未来估计？
09-10	Dyna、综合比较与选讲	怎样复用经验？ V 与 Q 各在何处发挥作用？

每个算法都回答：学习对象是什么？目标怎样构造？它怎样改变行动？

Bandit、DP、MC 控制、Dyna 与资格迹保留为本课的表格型 RL 主线补充。

强化学习：通过交互改善策略

强化学习（Reinforcement Learning, RL）研究：


如何根据行动后的奖励反馈，学会做出一连串更好的决策？

- **智能体（Agent）**：做决定的一方，例如在网格里移动的机器人。
- **环境（Environment）**：响应动作，返回反馈与新情境。
- **学习**：利用经历调整选择方式，让后续行动获得更好的结果。

核心理解

强化学习把“选择动作”和“从选择的后果中学习”放在同一个循环里。

交互时序与奖励下标




- $t = 0, 1, 2, \dots$ 表示依次发生的决策时刻。
- **状态 (State)** S_t : 现在依据什么情境做决定? 例如当前格子。
- **动作 (Action)** A_t : 现在做什么? 例如上、下、左、右。
- **奖励 (Reward)** R_{t+1} : 刚才这个动作带来多少即时反馈?

核心理解

先在时刻 t 做动作 A_t , 环境随后返回 R_{t+1} 和 S_{t+1} 。新状态又成为下一次决策的起点。

序贯决策与长期后果

悬崖行走 (Cliff Walking): 从起点 S (Start) 走向终点 G (Goal)。



- 序贯决策 (Sequential Decision Making): 当前动作改变下一步所处的情境。
- 两个动作现在都可能得 -1 , 但一个走向安全区域, 另一个靠近悬崖。

悬崖行走规则: 普通移动 (包括进入终点 G) 得 -1 ; 坠崖得 -100 并返回 S; 只有到 G 才结束。

核心理解

当前动作会影响未来还能做什么、会遇到什么。因此评价决策必须考虑长期后果。

表格型强化学习的表示

表格型强化学习 (Tabular RL): 为每个状态, 或每个状态与动作的组合, 单独存一个价值估计, 即对未来奖励的预测。

状态	动作	初始预测
格子 1	向上	0
格子 1	向右	0
格子 2	向上	0

各行独立, 初始值 0 仅作示意。

通常适合:

- 状态、动作有限且可逐个列出。
- 规模不大, 重要条目有足够经验。

如小型网格、少量老虎机。

例: 10 个状态, 每状态 4 个动作, 需要 $10 \times 4 = 40$ 个动作值条目。

核心理解

表格描述存值方式; 即使环境随机、转移规则未知, 也能使用表格型方法。

价值表与函数逼近

表格型方法 (Tabular Methods)

- 为每个状态或状态与动作的组合，单独存一个预测数值。
- 适合状态、动作数量较少的任务。

函数逼近 (Function Approximation)

- 用带共享参数的函数生成预测，例如神经网络。
- 一次更新可改变多个状态的预测。

核心理解

本合集先固定简单表示，集中研究：经验应当如何改变预测，预测又如何改变动作选择？

控制目标与 Prediction 的作用

控制的最终目标：找到长期期望回报更高的策略，理想情况下得到 π_* 。

分类维度	一类	另一类
任务	Prediction：评价给定策略	Control：改进策略
价值对象	$V(s)$ ：状态的长期评分	$Q(s, a)$ ：动作的长期评分


Prediction 是问题类型，不是必须先学 V 的步骤

固定策略估计 Q ，也是 Prediction。MC Control 可直接更新 Q 并改进策略，无需先训练一张 V 表。


再区分一种分类：书中的“价值学习 / 策略学习”描述实现路线；两者都能用于控制。

多臂老虎机：估计动作奖励


一次只拉一台机器的拉杆：选哪台，就是选择哪个动作。



未选择
没有新反馈



本次选择 B
随机奖励：+2



未选择
没有新反馈

核心理解

“臂”（Arm）对应一个可选动作。每台机器的平均奖励未知，只能通过反复尝试收集信息；同一台机器每次给的奖励也可能不同。

Bandit 的动作价值

多臂赌博机 (Multi-armed Bandit): 反复从 k 个动作中选一个, 每次只看到所选动作的奖励。

$$q_*(a) = \mathbb{E}[R_{t+1} \mid A_t = a], \quad Q_t(a) \approx q_*(a).$$

- a 是某个动作。竖线后的 $A_t = a$ 表示“已选择这个动作”。
- $q_*(a)$ 是该动作的真实平均奖励, $Q_t(a)$ 是时刻 t 的当前估计。
- 先假设平稳 (Stationary): 奖励分布不随时间改变, 但单次结果仍可随机。

核心理解

我们需要边估计、边选择, 使学习期间的累计奖励尽可能高。探索的代价也计入表现。

样本均值的增量更新

只看同一个臂： $R_1, \dots, R_n$ 是它的前 n 个奖励， $\bar{R}_n$ 是这 n 个数的样本均值 (Sample Average)。

$$\bar{R}_n = \frac{1}{n} \sum_{i=1}^n R_i.$$

对 $n \geq 2$ ，前 $n-1$ 项的和等于 $(n-1)\bar{R}_{n-1}$ ，所以

$$\bar{R}_n = \frac{(n-1)\bar{R}_{n-1} + R_n}{n} = \bar{R}_{n-1} + \frac{1}{n}(R_n - \bar{R}_{n-1}).$$

核心理解

新样本与旧均值的差决定修正方向。例如 $2 + \frac{1}{4}(6 - 2) = 3$ 。
第一项用 $\bar{R}_1 = R_1$ 初始化。

学习目标、步长与估计误差

把选中动作的旧估计写成 $Q(a)$ ，把本次观测奖励写成 R ：

$$Q(a) \leftarrow Q(a) + \alpha \underbrace{\left[\overset{\text{目标}}{R} - Q(a) \right]}_{\text{预测误差}}.$$

- 学习目标 (Learning Target) 是本次希望预测靠近的参考值，这里就是 R 。
- 步长 (Step Size) $0 < \alpha \leq 1$ 决定移动多少； $\leftarrow$ 表示更新表中条目。
- 例：旧值 2、目标 6、 $\alpha = \frac{1}{4}$ ，新值为 3。

核心理解

新估计 = 旧估计 + α (目标 - 旧估计)。

从样本平均，理解蒙特卡洛的基本思想

如果期望难以直接计算，可以从相应分布取样，再对结果求平均：

$$X_1, \dots, X_n \sim p, \quad \mathbb{E}_{X \sim p}[f(X)] \approx \frac{1}{n} \sum_{i=1}^n f(X_i).$$

- 赌博机：固定一个动作，多次奖励的平均估计其期望奖励。
- 序贯任务：固定策略，多次完整经历的回报平均估计长期价值。
- 样本均值可增量维护： $m_n = m_{n-1} + \frac{1}{n}[f(X_n) - m_{n-1}]$ 。

同一个名称，有宽窄两种用法

书第 2 章的 Monte Carlo 泛指采样估计期望；后文的 **MC 预测/控制** 特指用完整回报作目标。TD 也用采样，但其目标还包含当前价值估计。

贪心选择与探索不足

贪心 (Greedy) 选择当前估计最大的动作：

$$A_t \in \arg \max_a Q_t(a).$$

$\arg \max$ 返回使数值最大的动作；并列时可以从其中任选一个。

利用 (Exploitation) 按已有知识获利；探索 (Exploration) 尝试其他动作以获得信息。

核心理解

一次低奖励可能只是运气差。若从此不再尝试，智能体就无法纠正对这个臂的低估。

探索与利用： ϵ -贪心

ϵ -贪心 (ϵ -greedy) 用探索概率 $0 \leq \epsilon \leq 1$ 选择动作：

$$\begin{cases} \text{选择当前估计最大的动作,} & \text{概率 } 1 - \epsilon, \\ \text{从全部 } k \text{ 个动作中均匀随机选择,} & \text{概率 } \epsilon. \end{cases}$$

- ϵ 越大，分给随机尝试的机会越多。
- 四个动作、 $\epsilon = 0.1$ 时，唯一贪心动作的总概率为 $0.9 + 0.1/4 = 0.925$ 。

核心理解

ϵ 控制 “尝试哪个动作”； α 控制 “看到反馈后把估计改多少”。

上置信界 UCB (选讲)

置信上界 (Upper Confidence Bound, UCB) 将估计值与不确定性一起用于选择:

$$A_t \in \arg \max_a \left[\underbrace{Q_t(a)}_{\text{已有估计}} + c \underbrace{\sqrt{\frac{\ln(t+1)}{N_t(a)}}}_{\text{探索奖励项}} \right].$$

- $N_t(a)$ 是时刻 t 前选择 a 的次数, $c > 0$ 控制探索强度。
- 次数越少, 奖励项越大。未尝试过的动作先尝试一次, 避免除以零。

核心理解

评分同时考虑“看起来有多好”和“还有多不确定”。
探索奖励项影响动作选择, 不改变环境实际返回的奖励。

动作影响未来：悬崖行走

S			悬崖: -100, 返回 S								G

坐标 (x, y) : $x = 0, \dots, 11$ 从左到右;
 $y = 0, \dots, 3$ 自下而上。

- 状态是所在安全格子；动作是上、下、左、右。
- 普通移动奖励 -1 ，进入终点也为 -1 ；撞墙留在原地。
- 坠崖奖励 -100 并返回起点；**只有到达终点才结束。**

核心理解：悬崖行走 (Cliff Walking)

眼前两次移动可能都得到 -1 ，却把智能体带到风险不同的位置。比较动作时，必须考虑它们将怎样改变未来。

MDP 的组成

马尔可夫决策过程 (Markov Decision Process, MDP) 可写为

$$(\mathcal{S}, \mathcal{A}, P, R, \gamma).$$

- $\mathcal{S}$ 、 $\mathcal{A}$: 可能处于哪些**状态**, 以及可以选择哪些**动作**。
- $P(s' | s, a)$: 在 s 做 a 后, 转移到下一状态 s' 的概率。
- $R(s, a)$: 在 s 做 a 后的**期望即时奖励**; 不是一次实际观测。
- γ : 折扣因子 (Discount Factor), 稍后用它给未来奖励加权。

核心理解

模型 (Model) 回答 “这样做以后会发生什么”; 策略回答 “现在选择什么”。本例另行规定: 每次从起点 Start 开始。

转移与奖励的联合模型

联合模型 (Joint Model) 同时记录下一状态与奖励：

$$p(s', r \mid s, a) = \Pr(S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a).$$

- 竖线右侧：已知当前在 s ，并且采取动作 a 。
- 竖线左侧：下一状态为 s' ，且这一步收到奖励 r 。
- 小写 s, a, s', r 是具体取值；大写 S_t, A_t, R_{t+1} 是随机变量。

$$p(\text{Start}, -100 \mid (10, 1), \text{下}) = 1.$$

核心理解

模型告诉我们各种结果有多可能；一条真实经验只告诉我们这次发生了什么。

当前观测，是否已经包含决策所需的信息？

状态的要求：当前信息足以概括与未来有关的历史。

$$\Pr(S_{t+1}, R_{t+1} \mid S_t, A_t, H_t) = \Pr(S_{t+1}, R_{t+1} \mid S_t, A_t),$$

其中 H_t 是此前交互历史；这是本课使用的马尔可夫性条件。

同一格子，可能还缺少什么？

若风向每步交替并影响移动，仅知道位置不够；还需知道风向阶段。若阶段不可见，就需要利用过去的观测与动作推断。


观测 O_t 与状态 S_t 要区分

当前看到的信息未必足够。书中用局部迷宫视野说明：记住过去的信息，才能改善决策；随意叠加几帧并不保证恢复马尔可夫性。

轨迹、片段与终止状态

轨迹 (Trajectory) 记录连续发生的状态、动作与奖励:

$$S_0, A_0, R_1, S_1, \dots, S_{T-1}, A_{T-1}, R_T, S_T.$$



- 片段 (Episode): 从开始到终止的一段完整轨迹。
- T 是终止时刻; S_T 是终止状态 (Terminal State), 本例即终点。
- 坠崖后继续走, 仍属于同一个片段。
- 没有自然终点的任务, 称为持续任务 (Continuing Task)。

核心理解

一次经验是一种可能的未来。我们随后要把这条未来里的奖励合在一起评价。

奖励与回报

奖励 (Reward) R_{t+1} 是执行当前动作后得到的一步反馈。**回报 (Return)** G_t 把之后的奖励合在一起：

$$G_t = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{T-t-1} R_T.$$

- R_{t+1} ：接下来立即收到的奖励，权重为 1。
- γR_{t+2} ：再下一步奖励乘以未来权重 γ 。
- 终止后没有奖励，约定 $G_T = 0$ ；本例取 $\gamma = 1$ ，三步到终点则 $G_t = -3$ 。

核心理解

两个动作眼前都得到 -1 ，一个通向终点，一个通向危险区域；**回报**才能区分这些长期后果。

折扣因子与时间偏好

折扣因子 (Discount Factor) $0 \leq \gamma \leq 1$ 决定未来奖励的权重。

动作 A: 奖励 (5, 0)

先得 5, 再得 0, 随后终止。

$$G_A = 5 + \gamma \cdot 0 = 5.$$

动作 B: 奖励 (0, 100)

先得 0, 再得 100, 随后终止。

$$G_B = 0 + \gamma \cdot 100 = 100\gamma.$$

当 $\gamma > 0.05$ 时, 动作 B 的回报更高; $\gamma = 0$ 时只优化下一次奖励。

核心理解

γ 决定“未来有多重要”; 步长 α 决定“这次把估计改多少”。

策略：给定状态下的动作分布

策略 (Policy) 规定在每个状态下如何选择动作：

$$\pi(a | s) = \Pr(A_t = a | S_t = s), \quad \sum_a \pi(a | s) = 1.$$

- 给定状态 s ，为每个动作分配非负概率；各动作概率之和为 1。
- 例：在 $(10, 1)$ 向右的概率为 0.8，向下的概率为 0.2。
- $A_t \sim \pi(\cdot | S_t)$ 中， $\sim$ 表示从该分布采样一个动作。

核心理解

随机策略 (Stochastic Policy) 允许探索；确定性策略 (Deterministic Policy) 是以概率 1 选择某个动作的特殊情况。

期望究竟在平均哪些随机性？

在当前状态 s ，先由策略选动作，再由环境产生反馈：

$$A_t \sim \pi(\cdot \mid s), \quad (S_{t+1}, R_{t+1}) \sim p(\cdot, \cdot \mid s, A_t).$$

策略的随机性

同一格子，可以按 0.8/0.2 的概率选择不同方向。

即使环境转移确定，未来路线仍可能随机。

固定 s, a 只消去当前动作的选择；未来状态与未来动作仍可能随机。接下来， Q 与 V 都用期望给这些未来打分。

环境的随机性


动作已经选定，下一状态或奖励也可能有多个结果。

采用确定策略，也未必得到固定回报。

先给动作评分：动作价值比较的是什么？

未来回报还没发生，先用**条件期望**评价当前选择：

$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a].$$



- 固定当前状态 s 与第一步动作 a 。
- 从下一步开始，仍按**指定策略** π 行动。
- 对随后可能发生的奖励、状态与动作求平均。

为什么下标 π 不能省？

同一个格子、同一个第一步，后来由稳妥策略或冒险策略接手，长期结果会不同。
 $Q(s, a)$ 是表中的当前估计，目标才是 $q_{\pi}(s, a)$ 。

状态价值：按策略平均动作价值

动作尚未选定时，还需要对 $A_t \sim \pi(\cdot | s)$ 求平均：

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s] = \sum_a \pi(a | s) q_{\pi}(s, a).$$

- $q_{\pi}(s, a)$ ：第一步指定做 a ，之后按 π 走。
- $v_{\pi}(s)$ ：从第一步开始，就按 π 选择动作。
- 例：两动作的 q_{π} 为 2, 8，各选一半，则 $v_{\pi}(s) = 5$ 。

V 的作用是什么？

它把“从这里按此策略行动的表现”概括为一个数，可用于评估策略、构造后续预测，或配合已知模型改进动作。这里的 V 是估计表， v_{π} 是真实期望。

从动作评分到最优策略，还差什么？

q_π 评价 “以后按指定策略走”； q_* 评价 “以后尽可能走好”：

$$q_*(s, a) = \max_{\pi} q_\pi(s, a), \quad \pi_*(s) \in \arg \max_a q_*(s, a).$$

书中的动作选择例子

若同一状态下三个动作的最优动作值为

$$q_*(s, \text{左}) = 130, \quad q_*(s, \text{右}) = -50, \quad q_*(s, \text{上}) = 296,$$

就选择 “上”； 比较的是长期期望回报，不是下一步奖励。

Q 与 V 的关系： 准确的 q_* 足以提取最优策略； $v_*(s) = \max_a q_*(s, a)$ 可直接读出。当前 Q 是对 q_π 或 q_* 的估计，须看具体算法。

把“找到好策略” 写成一个明确目标

先约定每次从哪里出发： $S_0 \sim d_0$ ，其中 d_0 是固定的起始状态分布。

$$J(\pi) = \mathbb{E}_{\pi, S_0 \sim d_0}[G_0] = \sum_s d_0(s) v_\pi(s), \quad \pi_* \in \arg \max_{\pi} J(\pi).$$

若每次都从悬崖起点 Start 出发，就有 $J(\pi) = v_\pi(\text{Start})$ 。

价值学习路线

先学习长期评分，再由评分选动作。

本课主要使用表格 V 或 Q 。

Prediction 的位置：先回答“某策略能取得怎样的回报”；控制再利用评价改善选择。

策略学习路线

直接调整策略本身，让 $J(\pi)$ 提高。

本书后续以策略梯度展开。

阅读对照：书中记号与本课记号

两份材料采用不同记号，含义与时间顺序保持一致：

本书	本课	含义
R_t	R_{t+1}	执行 A_t 后收到的一步奖励
U_t	G_t	从当前动作开始的折扣回报
V_π, Q_π	v_π, q_π	指定策略的真实期望价值
表格或网络近似	V, Q	算法当前保存的估计
$\delta = \text{预测} - \text{目标}$	$\delta = \text{目标} - \text{预测}$	误差符号相反，更新方向一致

本课的终止与折扣约定

真正终止后 $G_T = V(S_T) = 0$ ，进入终点时的 R_T 仍计入回报。有界奖励、 $\gamma < 1$ 保证折扣回报有界； $\gamma = 1$ 的数例假设期望片段长度有限。

回报的一步递归

从回报定义中提出第一项：

$$\begin{aligned} G_t &= R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \cdots) \\ &= R_{t+1} + \gamma G_{t+1}. \end{aligned}$$

- G_{t+1} ：从下一时刻开始的剩余回报。
- 再乘 γ ：把整个剩余未来换算为当前时刻的权重。
- 三步到终点且 $\gamma = 1$ ： $-3 = -1 + 1 \times (-2)$ 。

核心理解

当前的长期回报 = 下一步奖励 + 折扣后的剩余长期回报。这条递归关系，是 Bellman 方程的起点。

从随机回报到 Bellman：哪一步用到了状态？

固定策略 π ，先对回报递归求条件期望：

$$v_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s].$$

若 S_{t+1} 已包含预测未来所需的信息，且之后按同一状态策略 π 行动，剩余回报的条件期望就可用 $v_{\pi}(S_{t+1})$ 表示：

$$v_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s].$$

三件事要区分

回报递归来自定义；用状态价值概括未来需要充分状态；Bellman 方程给出真实价值的自洽关系，求解或估计价值还需要 DP、MC 或 TD 等方法。

MDP、Bellman 方程与求解算法

MDP: 规定状态、动作、转移与奖励规律; 给定策略后可定义长期价值。

回报递归: $G_t = R_{t+1} + \gamma G_{t+1}$, 由累计奖励定义直接得到。

状态版 Bellman: 用后继状态价值概括剩余回报的期望:

$$v_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s].$$

- 状态须包含预测未来所需的信息; 策略也须按该状态决定动作。
- 上式按平稳 MDP 与平稳状态策略书写; 有限时域可使用时间相关价值或把时间纳入状态。

马尔可夫性用在哪里?

回报递归本身无须马尔可夫性; 把未来概括为仅依赖 S_{t+1} 的价值, 需要足够的状态信息。DP 将这个关系变成计算, TD 用一步采样构造更新目标。

反例：相同观测 X，未来却取决于起点

初始等概率位于 A 或 B；两步后终止， $\gamma = 1$ 。无动作选择，观测 O_t 只记位置。

起点	观测路线	第一步奖励	最后一步奖励
A	$A \rightarrow X \rightarrow G$	0	+10
B	$B \rightarrow X \rightarrow G$	0	-10

在 X 时，环境仍保留起点信息，但当前观测把它丢掉了：

$$\mathbb{E}[G_1 \mid O_1 = X, O_0 = A] = 10, \quad \mathbb{E}[G_1 \mid O_1 = X, O_0 = B] = -10.$$

为什么只记 X 不够？

相同观测下，历史仍改变未来奖励； $O_1 = X$ 不能独立概括这段未来。

把两段历史压成一个平均，哪里会出错？

只按观测 X 分组，定义一个混合平均：

$$\bar{v}(X) = \mathbb{E}[G_1 \mid O_1 = X] = \frac{1}{2}(10) + \frac{1}{2}(-10) = 0.$$

但从 A 出发的真实期望回报为 10，错误的一步替换却得到 $0 + \bar{v}(X) = 0$ 。

错误不是求平均，而是丢掉了仍有用的条件

$$\mathbb{E}[G_1 \mid O_0 = A, O_1 = X] = 10 \neq \mathbb{E}[G_1 \mid O_1 = X] = 0.$$


修复：状态改为“位置、起点”。于是

$$v((X, A)) = 10, \quad v((X, B)) = -10,$$

从 A 出发就能正确递推 $0 + 10 = 10$ 。

Bellman 备份的数值计算

在 $s = (10, 1)$, 取 $\gamma = 1$; 下图给出策略概率、奖励与当前估计。



$$\underbrace{0.8[-1 + (-2)]}_{\text{右移分支贡献}} + \underbrace{0.2[-100 + (-20)]}_{\text{下移分支贡献}} = -26.4.$$

核心理解：回溯 (Backup)

分支上先算“奖励 + 后继估计”，再按概率平均。 -26.4 是本次更新目标；后继估计变了，目标也会改变。

Bellman 期望中的两层平均（选讲）

$$v_{\pi}(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')].$$

- 内层 $\sum_{s', r}$: **固定动作**，对可能的下一状态与奖励求平均。
- 外层 $\sum_a$: 再按策略对**不同动作**求平均。
- 联合模型还给出 $P(s' | s, a) = \sum_r p(s', r | s, a)$ 。

$$R(s, a) = \sum_{s', r} r p(s', r | s, a) \quad \text{是即时奖励的期望。}$$

核心理解

看似复杂的公式，仍然只是在重复一件事：列出可能后果，按概率加权。

最优价值与 Bellman 最优方程

最优状态值 (Optimal State Value) 比较所有策略:

$$v_*(s) = \max_{\pi} v_{\pi}(s).$$

贝尔曼最优方程 (Bellman Optimality Equation) 把第一步改为选择最好动作:

$$v_*(s) = \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a].$$

- $\max_a$: 比较在当前状态可以选择的动作。
- $\mathbb{E}$: 选定动作后, 仍对环境可能产生的结果求平均。

核心理解

评估按当前策略**平均动作**; 最优性要求**选择最好动作**。两者都考虑即时奖励与未来价值。

Q 的 Bellman 方程：下一动作平均，还是取最好？

给定策略：下一动作仍按 π 选择。

$$q_{\pi}(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma \sum_{a'} \pi(a' | s') q_{\pi}(s', a') \right].$$

最优控制：下一状态起总是选择最好动作。

$$q_*(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right].$$

- 当前动作 a 已给定；比较或平均的是**下一状态的动作** a' 。
- 可选择动作，不能选择环境一定产生什么结果：对 s', r 仍求期望。

与 TD 控制的联系： Sarsa 采样下一动作，学习当前策略的后果；Q-learning 的目标采用下一状态的最高评分。

动态规划：固定策略的价值评估

动态规划 (Dynamic Programming, DP) 用已知模型反复计算。策略评估 (Policy Evaluation) 先固定 π ，估计 v_π ：

$$Y_k(s) = \mathbb{E}_\pi[R_{t+1} + \gamma V_k(S_{t+1}) \mid S_t = s], \quad V_{k+1}(s) \leftarrow Y_k(s).$$

- 目标是什么？ $Y_k(s)$ 是用当前值表算出的完整期望。
- 需要什么？策略 π 、环境模型 p 与当前值表 V_k 。
- k 是计算轮次， t 是环境时间；逐轮更新各状态，终点值保持 0。

核心理解

把 Bellman 关系变成反复计算：当前估计用于预测未来，新目标用于修正现在。

同步策略评估（选讲）

$$V_{k+1}(s) = \sum_a \pi(a | s) \sum_{s', r} p(s', r | s, a) [r + \gamma V_k(s')].$$

1. 给每个非终止状态设一个初始估计，例如 $V_0(s) = 0$ 。
2. 固定策略 π ；对每个状态，按模型算出右侧加权平均。
3. 得到新表 V_{k+1} 后，再开始下一轮；值变化足够小时停止。

核心理解

“对模型精确求期望”不等于“已经知道真实值”。后继估计也在更新，所以通常需要多轮计算。

为什么已知模型时，学 V 也能改进策略？

只有 $v_\pi(s)$ 的一个分数，还不能直接比较该状态的动作；环境模型补上一步前瞻：

$$q_\pi(s, a) = \sum_{s', r} p(s', r | s, a) [r + \gamma v_\pi(s')].$$

策略改进：比较各动作的一步目标，令

$$\pi'(s) \in \arg \max_a q_\pi(s, a).$$

- 已知模型： V 加上模型，可以算出用于选动作的评分。
- 无模型且直接学 Q ：动作评分已在表中，可直接比较，无须再训练 V 。

这是改进一步，不是一步到最优

在标准条件下，基于真实 q_π 的贪心改进不会变差；新策略改变了未来，通常还要继续评估与改进。

策略迭代：评估与改进

策略迭代 (Policy Iteration) 交替执行两种计算：

$$\pi_0 \xrightarrow{\text{评估}} v_{\pi_0} \xrightarrow{\text{改进}} \pi_1 \xrightarrow{\text{评估}} v_{\pi_1} \longrightarrow \dots$$

1. **评估**：固定当前策略，充分计算它的值函数。
2. **改进**：依据这些值，选择更好的动作。
3. **重复**：新策略改变了未来，因而需要重新评估。

核心理解

值函数帮助我们修改策略；策略修改后，值函数也需要跟着更新。在标准条件下，改进不再改变策略时得到最优策略。

值迭代：反复进行最优备份

值迭代 (Value Iteration) 把一步前瞻与选择最佳动作合在一起：

$$V_{k+1}(s) = \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma V_k(s')].$$


- 对每个动作，先算“即时奖励 + 后继估计”的期望。
- 在这些动作目标中取最大值，作为当前状态的新估计。
- 值稳定后，在每个状态选取使该目标最大的动作，形成策略。

核心理解

策略迭代先充分评估再改进；值迭代每做一次前瞻，就立即比较最佳动作。

广义策略迭代 GPI

广义策略迭代 (Generalized Policy Iteration, GPI):



- 评估主要改变值估计；改进主要改变行为规则。
- 两者可以尚未完全结束就交替；后续算法会改变评估时使用的目标。

核心理解

控制 (Control) 让值估计与动作选择相互推动，逐步改进长期行为。

策略评估、策略迭代与值迭代

共同条件：环境模型已知，可计算奖励与后继价值的期望。

方法	任务	计算过程
策略评估	Prediction	固定 π ，反复更新 V ，估计 v_π
策略迭代	Control	充分评估当前策略，再贪心改进；重复两阶段
值迭代	Control	备份取最佳动作目标，最后提取策略

对当前估计，定义一步动作目标：

$$Y_k(s, a) = \sum_{s', r} p(s', r | s, a) [r + \gamma V_k(s')].$$

评估按策略平均： $V_{k+1}(s) = \sum_a \pi(a | s) Y_k(s, a)$ 。

值迭代取动作最大值： $V_{k+1}(s) = \max_a Y_k(s, a)$ 。

三状态算例：立即结束或经 A 到达

状态为 S、A、G；G 是终点， $V(G) = 0$ ， $\gamma = 1$ 。

当前状态	动作	下一状态	奖励
S	立即结束	G	+1
S	先去 A	A	0
A	结束（唯一动作）	G	+3

直接结束： $S \rightarrow G$ ，回报为 1。

经过 A： $S \rightarrow A \rightarrow G$ ，回报为 $0 + 3 = 3$ 。

初始策略

在 S 立即结束；在 A 结束。所有转移确定且模型已知，片段最多两步。

三状态算例：策略评估与改进

1. 评估初始策略：在 S 直接结束，因此

$$v_{\pi_0}(S) = 1, \quad v_{\pi_0}(A) = 3, \quad v_{\pi_0}(G) = 0.$$

2. 用旧策略的后继价值比较 S 的动作：

$$q_{\pi_0}(S, \text{立即结束}) = 1 + v_{\pi_0}(G) = 1,$$

$$q_{\pi_0}(S, \text{先去 } A) = 0 + v_{\pi_0}(A) = 3.$$

3. 改进并重新评估：新策略 π_1 在 S 选择先去 A, $v_{\pi_1}(S) = 3$ ；再次改进不再改变动作。

两个不同层次

只算初始策略的价值是 Prediction；评估后改动作并继续评价，是 Control。即使初始策略从 S 不到 A，也可以按模型评价从 A 出发的价值。

三状态算例：值迭代

从 $V_0(S) = V_0(A) = V_0(G) = 0$ 开始，终点值固定为零。

$$V_{k+1}(S) = \max\{1, 0 + V_k(A)\}, \quad V_{k+1}(A) = 3.$$

同步计算轮次	$V(S)$	$V(A)$
初始	0	0
第 1 轮	$\max(1, 0) = 1$	3
第 2 轮	$\max(1, 3) = 3$	3

价值稳定后，在 S 比较 1 与 $0 + 3$ ，提取动作“先去 A ”。

与策略迭代的差别

每次备份取最佳动作目标，无须先完整评估固定策略。同步更新用上一轮的表； A 的奖励下一轮才传到 S 。

案例的奖励与终止规则

	悬崖行走	校园送件
用于说明	MDP、DP、探索行为	MC、TD、控制与 Dyna
普通移动	-1	-1
进入终点 G	-1, 片段终止	+10, 片段终止
特殊转移	坠崖 -100, 回起点继续	按地图选择相邻房间
终止后价值	$V(G) = 0$	$V(G) = 0$


校园送件的 +10 替代普通移动的 -1, 不再另扣一步成本。

后续数例主要使用校园送件; 比较探索风险时会明确回到悬崖行走。

校园送件的状态、动作与奖励

用马尔可夫决策过程（MDP）描述移动：先选房间，再观察奖励与新位置。

$$S_t \xrightarrow{A_t} (R_{t+1}, S_{t+1}).$$



连线可双向通行；从 O 出发，送到 G。

- **状态**：所在房间；**动作**：选择一个相邻房间。
- 普通移动得 -1 ；送达 G 的那一步得 $+10$ ，**立即结束**。
- 一次片段（Episode）就是一次完整送件。

核心理解

地图与目标固定时，当前位置足以描述决策情境，满足 Markov 性。


蒙特卡洛预测

Monte Carlo Prediction

用一次完整送件的实际回报，评估当前策略。

固定策略下的完整片段

先固定策略 π ：不能用模型算出期望，就反复执行它，观察实际表现。



- 轨迹 (Trajectory): 依次记录状态、动作、奖励，如图中这次实际送件。
- 一次片段 (Episode) 是一轮完整送件; T 是终止时刻。
- 每次得到一个实际回报; 多次结果用来估计 $v_{\pi}(s)$ 。

核心理解

蒙特卡洛 (Monte Carlo, MC) 的起点: 把策略执行出来, 用结果评价它。

完整回报：直接路线与绕路路线

固定策略下的两次可能经历；图上标出每一步的实际奖励 ($\gamma = 1$):



$$\underbrace{G_{T-3}}_{\text{三步送达这次, 从 O 开始}} = R_{T-2} + R_{T-1} + R_T = -1 - 1 + 10 = 8.$$

送达后 $G_T = 0$, 但 $R_T = +10$ 仍要计入; 绕路则多花两步时间。

核心理解

回报把整次送件变成一个数: 既计入送达奖励, 也计入沿途花费。

回报的倒序计算

不只办公室 O 需要评价。沿途的大厅 A、走廊 B 也各有一个回报：

$$G_t = R_{t+1} + \gamma G_{t+1}, \quad G_T = 0.$$



$$G_{T-3} = 8 \xleftarrow{-1 + 9 = 8} G_{T-2} = 9 \xleftarrow{-1 + 10 = 9} G_{T-1} = 10 \xleftarrow{10 + 0 = 10} G_T = 0$$

从终点开始，沿下排向左计算


核心理解

行动按时间向右发生；回报从终点向左计算。相加的都是已发生的奖励，没有用预测。

怎样把一次回报变成一次学习？

固定策略： $v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$ ； $V(s)$ 保存当前估计。

$$V(S_t) \leftarrow V(S_t) + \alpha[G_t - V(S_t)].$$




核心理解

目标为完整回报 8；步长（Step Size） $\alpha = 0.5$ 控制移动幅度。

$4 + 0.5(8 - 4) = \boxed{6}$ ：向样本靠近一点，不把一次回报当作真值。

第 n 个选中样本取 $\alpha_n = 1/n$ ，更新恰为样本平均；固定步长则是加权更新。

首次访问与每次访问



首次访问 (First-visit)

只使用 $G_1 = -1 - 1 - 1 + 10 = 7$ 。

选择本片段中正向时间最早的一次访问。

每次访问 (Every-visit)

使用 $G_1 = 7$ 和 $G_3 = -1 + 10 = 9$ 。


每次访问都计算从那时起的回报。

核心理解


访问时刻决定对应回报；两种方法都估计同一个 $v_{\pi}(s)$ 。

首次访问 MC: 从送件记录到价值表的四步

固定策略 π 。同一片段中，大厅 A 的首次回报是 7，不是后面的 9：



更新: $V(S_t) \leftarrow V(S_t) + \alpha[G_t - V(S_t)]$ 。



1. 按 π 走到终点，保存片段。
2. 从 $G_T = 0$ 倒推各 G_t 。
3. 重置“已访问”，按时间扫描。
4. 首次出现才更新，计数并标记。

核心理解

新片段重置“首次”记录，保留值表；多次经历积累对同一策略的评价。


蒙特卡洛控制

Monte Carlo Control

有了评价，还要用它决定下一次怎么走。

固定策略学 Q，仍然是在做预测

动作价值： $q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a]$ 。



- 在 s 先做 a ，之后按 π 继续送达 G ：长期表现如何？
- 两个动作都先得 -1 ； Q 分别记录它们的长期评分。
- 需要带动作的完整记录；目标仍是对应回报 G_t 。

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[G_t - Q(S_t, A_t)].$$

核心理解

固定 π 时，更新 Q 仍是 Prediction；依据 Q 改善策略，才进入 Control。


让动作评分改变策略，再用新策略收集经验

MC 控制 (MC Control): 不再只评价固定策略，而是反复评估和改进。

1. 片段内固定当前策略；结束后用回报更新 Q 。
2. 改为关于当前 Q 的 ϵ -贪心策略。
3. 生成新片段，再评估、再改进。

$$\pi(a | s) \geq \frac{\epsilon}{m}, \quad m = \text{可选动作数}.$$

这是 ϵ -软策略 (ϵ -soft Policy) 的概率下界。



$$\epsilon = 0.3, \quad m = 3$$

核心理解

广义策略迭代 (Generalized Policy Iteration, GPI): 值表改进策略，策略产生新经验。固定 $\epsilon > 0$ 保留探索，不能直接宣称收敛到最优确定性策略。

MC Prediction 与 Control 的流程

步骤	Prediction	Control
初始化	固定策略 π , 初始化 V 或 Q	初始化 Q 与带探索的策略
收集	按固定 π 走完片段	按当前策略走完片段
更新	算 G_t , 更新对应的 V 或 Q	算 G_t , 更新对应的 Q
继续	保持 π , 收集下一片段	按 Q 改善策略, 保留探索, 再收集

两者都使用完整回报; N 按状态或状态-动作条目计数, $\alpha = 1/N$ 是增量平均。

首次访问版本

状态预测取首次出现的 s ; 动作值预测与控制取首次出现的 (s, a) 。Control 的策略会变化, 累计 Q 是持续修正的估计, 不是对当前策略的一次精确评估。

Prediction 的作用与 V 的算法依赖

MC Control 的实现路线：收集完整片段，更新 Q ，改善策略，继续探索。这个流程无需先学习一张 V 表。

课程先讲 Prediction，先集中理解：

1. 完整片段怎样提供回报样本 G_t ？
2. 怎样把样本归到某个状态或状态-动作对，并估计期望？
3. 固定策略学会估计后，再引入策略变化与探索。

同样可行的教学起点

固定策略估计 q_π ，本身就是 Q Prediction。在此基础上加入策略改进，就进入 MC Control。先讲 V 是概念与教学选择，不是 Q 控制算法的前置计算步骤。

MC 的等待时间与样本波动



同一办公室出发；每次都要等到 G，才得到本次完整目标。

好处

- 无需模型，也不借用当前价值预测。
- 目标来自真实发生的后续奖励。

代价


- 必须等终止；无终点不能直接用。
- 探索绕行可能使回报波动较大。

核心理解

MC 不用预测来补全未来；因此，它也必须等未来真的发生。

一步经验中已知与未知的信息

先固定策略，专注于学习目标。刚从办公室 O 到大厅 A 时：



$$G_t = \underbrace{R_{t+1}}_{\text{已经观察到}} + \gamma \underbrace{G_{t+1}}_{\text{还需等待的真实回报}} .$$

从 MC 过渡到 TD

用当前对未来的预测代替尚未观察到的未来回报，就能提前构造更新目标。

时序差分预测


Temporal-Difference Prediction

用已观察的一步奖励，加上对剩余未来的预测。

TD(0) 的一步目标

固定策略的 Bellman 关系:

$$v_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s].$$



$$Y_t = \underbrace{R_{t+1}}_{\text{刚观察到的奖励}} + \gamma \underbrace{V(S_{t+1})}_{\text{对剩余未来的当前预测}}.$$


- 用一次转移构造期望的样本; 用当前 V 代替未知 v_{π} 。
- 真正终止时未来项为 0, 因此 $Y_t = R_{t+1}$ 。

目标的误差: 目标包含真实观测, 也包含估计误差; 单次目标不保证比旧值更准确。

有了新目标，怎样修正当前预测？

非终止转移：先算差距，再修正。

$$\delta_t = \underbrace{R_{t+1} + \gamma V(S_{t+1})}_{Y_t: \text{目标}} - \underbrace{V(S_t)}_{\text{旧预测}}, \quad V(S_t) \leftarrow V(S_t) + \alpha \delta_t.$$




- δ_t : 时序差分误差 (TD Error), 即目标减旧值; 正则提高, 负则降低。
- α 是步长 (Step Size); $0 < \alpha \leq 1$ 控制一次改多少。

核心理解

更新骨架没有变：旧估计 $+\alpha \times (\text{目标} - \text{旧估计})$ 。

TD(0) 的一次数值更新

只观察 O 到 A 这一步；取 $\gamma = 1$ 、 $\alpha = \frac{1}{2}$ 。




到这里为止，真实送件尚未结束
 $V(A) = 9$ 只是当前预测

目标： $Y_t = -1 + 9 = 8,$

误差： $\delta_t = 8 - 4 = 4,$

$$V(O) \leftarrow 4 + \frac{1}{2} \times 4 = \boxed{6}.$$




核心理解

TD 已经学习了一次，虽然这段旅程还没有结束。

自举：用后继估计构造目标

自举 (Bootstrapping)：把另一个当前价值估计作为本次目标的一部分。


还未送达：借用未来预测



$$Y = -1 + \gamma V(A).$$

图中的虚线：价值预测传回前一状态；它可能带有估计误差。

已经送达：不再有未来奖励



$$Y = 10 + \gamma \times 0 = 10.$$


核心理解

自举让学习提前发生； $V(G) = 0$ 不会抹去进入 G 时得到的 $+10$ 。

TD(0) Prediction 的交互循环

要估计: v_π ; 需要: 一个转移、固定策略 π 与当前 V 表。

1. 初始化 V , 固定 $V(G) = 0$; 按 π 行动, 观察本步转移。
2. 构造目标: 未终止时 $Y_t = R_{t+1} + \gamma V(S_{t+1})$; 终止时 $Y_t = R_{t+1}$ 。
3. 更新离开的状态: $V(S_t) \leftarrow V(S_t) + \alpha[Y_t - V(S_t)]$ 。
4. 未终止就继续; 到达 G 后开始新的片段, 重复送件。



核心理解

行为规则不变; 每一步都修正预测, 再用新的送件经历继续学习。

真正终止、返回起点与外部截断

取 $\gamma = 1$, 一步 TD 目标为 $Y = R_{t+1} + V(S_{t+1})$ 。

校园送达 G: $Y = 10 + 0 = 10$,

悬崖行走走到 G: $Y = -1 + 0 = -1$,

坠崖后返回 S: $Y = -100 + V(S)$.

- 只有真正终止，才把后续价值设为零。
- 返回起点后仍继续行动，必须保留后续价值。
- 外部时间限制导致的截断，不自动等于任务终止。


MC 与 TD: 完整回报和一步目标

Monte Carlo: 完整经历



包含途中是否绕行及所有奖励

TD: 一步观测 + 预测



未发生的未来, 由当前估计补上

$$Y_t = G_t.$$

$$Y_t = R_{t+1} + \gamma V(S_{t+1}).$$

比较项	MC	TD(0)
环境模型 / 自举	不需要 / 否	不需要 / 是
是否等待片段结束	是	否

核心理解

MC 等到实际未来出现; TD 提前更新, 代价是目标会受当前估计误差影响。

等到真实结果，就一定更准确吗？

回到悬崖行走：同一格子、同一策略，这次可能顺利到达终点，下次可能探索失误而掉下悬崖。

$$\underbrace{\mathbb{E}_{\pi}[G_t \mid S_t = s]} = v_{\pi}(s)$$

固定策略、回报可积时，MC 目标在平均意义上正确


- **方差 (Variance)**: 不同经历让目标波动，完整回报常有较大波动。
- **偏差 (Bias)**: TD 使用不准确的 V 时，目标平均值也可能偏离真实值。
- TD 通常减少对遥远随机未来的直接采样，但目标方差并非总比 MC 小。

核心理解

MC 和 TD 的取舍包括等待时间、目标波动和估计误差，不能只凭“真实”或“预测”判断优劣。

DP、MC 与 TD 的目标来源

方法	采样 (Sampling) ?	自举 (Bootstrapping) ?	目标来源
DP	否	是：自举	模型的完整期望
MC	是	否	完整样本回报
TD	是	是：自举	一步样本与预测



每支目标 $-1 + \gamma V(s')$
大厅 A 再按 π 加权



办公室 O 到教室 G
等这次送达，得到完整回报



办公室 O 到大厅 A
只采样一步，其余用预测

核心理解

DP：完整期望 + 自举；MC：采样、不自举；TD：采样 + 自举。


从价值预测到行为控制

From Prediction to Control

把一步学习用于动作评分，让预测帮助我们选择行动。


沿用动作值 Q ，把一步学习用于行动选择

状态值预测：固定 π



整个状态只有一个评分
“处在这里有多好？”

动作值：可用于预测，也可用于控制



$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a], \quad Q(s, a) \approx q_{\pi}(s, a).$$

固定 π 学 Q 是预测；用 Q 改善 π 才是控制。现在把完整回报换成一步目标。


核心理解

没有转移模型时，直接学习动作值，可以比较不同动作的长期后果。

更新动作评分之前，先明确“以后按谁的规则走”


行为策略 (Behavior Policy) b

$b(a | s)$: 实际选择动作的概率。



目标策略 (Target Policy) π

$\pi(a | s)$: 想学习其表现的规则。



示例：目标只选当前最高 Q
不要求真实行为停止探索

例： $\epsilon = 0.3$ ，唯一贪心动作是去 B。

- 同策略 (On-policy): $b = \pi$; 异策略 (Off-policy): b 可以不同于 π 。
- Off-policy 也可在线学习; 数据覆盖仍必要, 经验回放不是必需步骤。

核心理解

谁负责行动，与目标假设今后怎样行动，可以是两套规则。


Sarsa: 同策略控制

Sarsa: On-policy Control

让学习目标与实际执行的行为规则保持一致。

Sarsa 的目标，接上实际选出的下一动作

固定 π : 评估 q_π ; 控制: 用 ϵ -贪心随 Q 改善策略。



分支框: $Q(A, \text{动作})$; 虚线尚未执行。

名字来自五项经验: $S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1} \rightarrow S, A, R, S', A'$; 撇号表示下一时刻。

核心理解

Sarsa 是 On-policy: 两个动作都按同一行为规则选出, 目标包含探索的后果。


$$Y_t = R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}).$$

- 一步奖励, 接上实际下一动作的评分。
- 即使探索选了去 C, 也用 $Q(A, \text{去 C}) = 2$ 。
- 需要转移、选出的下一动作与 Q 表。

Sarsa 的数值更新

本次误差： $\delta_t^S = Y_t - Q(S_t, A_t)$ 。

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)].$$



- 只改本次访问的状态-动作条目；后续 ϵ -贪心选择使用新的 Q 。
- 终止时目标只有 R_{t+1} ，不再选择下一动作。

核心理解

评价当前行为，再依据评价改善行为：这仍是广义策略迭代（GPI）。

Q-learning: 异策略控制

Q-learning: Off-policy Control

实际行为继续探索，目标改为采用贪心下一动作。

Q-learning: 从最优方程到可执行更新

第一步：写出最优动作值必须满足的关系。

$$q_*(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid s, a \right].$$

第二步：观察一条转移，用当前表替代未知真值。

$$Y_t = \begin{cases} R_{t+1}, & \text{若本步真正终止,} \\ R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a'), & \text{否则.} \end{cases}$$

第三步：把访问条目向这个采样目标移动。


$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[Y_t - Q(S_t, A_t)].$$

两个近似：一次观测采样期望，当前 Q 自举未来； $\max$ 来自最优 Bellman 方程。

Q-learning 的贪心目标

要估计：最优动作值 $q_*(s, a) = \max_{\pi} q_{\pi}(s, a)$ ； Q 是当前估计。

$$Y_t = R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a').$$



分支框： $Q(A, \text{动作})$ ；目标选最高分。

- a' 遍历候选动作； $\max$ 取最高的当前评分。
- 在大厅取 $\max(9, 4, 2) = 9$ ，无需等待实际下一动作。
- 只需要一个转移与 Q 表；行为仍可探索。

核心理解

Q-learning 是 Off-policy：目标中的动作规则可以不同于收集数据的行为规则。

Q-learning 的数值更新

$$\delta_t^Q = R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t),$$

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \delta_t^Q.$$

$Q(O, \text{去 } A)$ 向较高目标靠近; $\gamma = 1, \alpha = \frac{1}{2}$




- 上标 Q 标记本次 Q-learning 误差; Sarsa 则用实际下一动作的评分。
- 终止时未来项为 0; 充分探索与合适步长等条件仍不可省略。

核心理解

相同的更新骨架, 不同的未来行为假设, 产生不同的学习目标。

同一转移下的 Sarsa 与 Q-learning



Sarsa: 实际下一动作

$$Y_t = -1 + 2 = 1.$$

$$Q \leftarrow 5 + \frac{1}{2}(1 - 5) = \boxed{3}.$$

核心理解

奖励相同；分歧在于“下一步实际会做什么”与“贪心会做什么”。

分支值均为大厅 A 的 $Q(A, \text{动作})$ 。

$$Q(O, \text{去 } A) = 5, \quad \gamma = 1, \quad \alpha = \frac{1}{2}.$$

本次探索选择去 C，因此实际下一动作的当前评分为 2。

Q-learning: 最大动作值


$$Y_t = -1 + 9 = 8.$$

$$Q \leftarrow 5 + \frac{1}{2}(8 - 5) = \boxed{6.5}.$$


标准在线循环：行动、学习，再行动

准备：初始化 Q ，以 ϵ -贪心选当前动作；用 s, a, r, s' 简记经验。

1. 执行 a ，观察 r, s' 。若终止，令 $Y = r$ ，本次更新后结束片段。
2. 否则构造目标：
Sarsa：先按行为策略选 a' ， $Y = r + \gamma Q(s', a')$ 。
Q-learning： $Y = r + \gamma \max_{a'} Q(s', a')$ 。
3. 更新 $Q(s, a) \leftarrow Q(s, a) + \alpha[Y - Q(s, a)]$ 。
4. 移到 s' ；Sarsa 执行已选的 a' ，Q-learning 按行为策略选下一动作。



$Y = 10$ ，结束片段




尚未送达，继续自举
回到起点不等于终止

核心理解

每次只改一个条目；不断重复交互与更新，让动作选择随估计逐步改善。

学习目标与最终路线



两种算法可能都偏好 $O \rightarrow A \rightarrow B \rightarrow G$ 。

核心理解


区别在学习目标如何看待下一动作，不能只凭最终路线判断算法。

同样到达大厅 A，下一步如何计入目标？

- Sarsa：按实际策略选出的动作，例如探索去 C。
- Q-learning：当前评分最高的动作，例如贪心去 B。

持续探索下的悬崖行走

Sarsa: 考虑实际探索后果



Q-learning: 学习贪心目标



固定 $\epsilon > 0$ 时，远离悬崖可能减少探索导致的 -100 ；Sarsa 的目标反映这项代价。

核心理解

贪心最优路线只需 13 步；实际探索仍可能掉落。图中较安全路径仅为示意。

“会更新”与“收敛到最优”，还差哪些条件？

一个标准保证的设置：有限状态与动作、奖励有界、 $0 \leq \gamma < 1$ 。

- 每个 (s, a) 都要被无限次访问与更新。
- 对该条目的第 n 次更新，步长满足

$$\sum_{n=1}^{\infty} \alpha_n(s, a) = \infty, \quad \sum_{n=1}^{\infty} \alpha_n^2(s, a) < \infty.$$

Q-learning

上述条件下可学到 q_* 。行为可以持续探索；最终取关于 q_* 的贪心策略得到 π_* 。

Sarsa Control

还需行为在极限上贪心，同时保持无限探索（GLIE）。固定正 ϵ 不满足这个要求。

注意适用条件： 固定步长在有噪声时通常持续波动； $\gamma = 1$ 需另加适当终止等条件。

一步、多步和整段回报，是同一条目标链

固定策略预测：多观察几步奖励，再用当前估计接上尚未发生的未来。

一步：尽早更新

$$G_t^{(1)} = R_{t+1} + \gamma V(S_{t+1}).$$

一个实际奖励，加一个后续预测。

两步：多等一份证据

$$G_t^{(2)} = R_{t+1} + \gamma R_{t+2} + \gamma^2 V(S_{t+2}).$$

两个实际奖励，再接后续预测。

- 一直观察到终点，自举项消失，就得到 MC 的完整回报 G_t 。
- 更多真实奖励，减少对后续估计的依赖；也需要等待更多交互。

与本书的连接

本书对 Q 推导这条目标链；同样的分解也适用于这里的 V 预测。

多步目标：实际奖励加剩余预测

令 n 为观察步数， T 为片段终止时刻。若 $t + n < T$:

$$G_t^{(n)} = \underbrace{\sum_{k=1}^n \gamma^{k-1} R_{t+k}}_{\text{前 } n \text{ 步: 真实奖励}} + \underbrace{\gamma^n V(S_{t+n})}_{\text{此后: 当前估计}} .$$

- 若 $t + n \geq T$ ，只累加到终点，目标就是 G_t ，不再自举。
- $n = 1$ 是 TD(0)；观察完整剩余片段时得到 MC 目标。

$$V(S_t) \leftarrow V(S_t) + \alpha [G_t^{(n)} - V(S_t)] .$$

同一目标，不同信息量

仍在估计 v_π ；改变的是观测长度、对估计的依赖，以及可更新的时机。

多步学习也能直接更新 Q

多步 Sarsa: 按同一策略 π 采样轨迹, 把末端的 V 换成动作值 Q 。若 $t + n < T$:

$$G_{t,Q}^{(n)} = \sum_{k=1}^n \gamma^{k-1} R_{t+k} + \gamma^n Q(S_{t+n}, A_{t+n}).$$

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [G_{t,Q}^{(n)} - Q(S_t, A_t)].$$

- A_{t+n} 由策略 π 选择; 途中动作也必须与该同策略设定一致。
- 终止时去掉自举项; 两步目标例如 $-1 + \gamma(-1) + \gamma^2 Q(S_{t+2}, A_{t+2})$ 。

从预测到控制

固定 π : 预测 q_π 。再以 Q 改善策略: 形成多步控制; 无需先学习 V 。

λ -回报：混合不同长度的目标（选讲）

TD(λ): 混合多种观察长度

$0 \leq \lambda \leq 1$ 控制权重： λ 越大，越重视包含更多实际奖励的长目标。

例：当前离终点还剩 3 步，取 $\lambda = \frac{1}{2}$ ：

$$G_t^\lambda = \underbrace{\frac{1}{2} G_t^{(1)}}_{\text{看一步}} + \underbrace{\frac{1}{4} G_t^{(2)}}_{\text{看两步}} + \underbrace{\frac{1}{4} G_t}_{\text{看到结束}} .$$

- 三种目标给出三个预测；权重之和为 1，因此仍是一个回报预测。
- $\lambda = 0$ 使用单步目标； $\lambda = 1$ 使用完整回报目标。

核心理解

λ 在“尽早相信预测”与“更多依靠长期实际结果”之间调节。

有限片段的 λ -回报（选讲）

对还剩 $T - t$ 步的片段， λ -回报（ λ -return）定义为

$$G_t^\lambda = \underbrace{(1 - \lambda) \sum_{n=1}^{T-t-1} \lambda^{n-1} G_t^{(n)}}_{\text{尚未看到终点的各个长度}} + \underbrace{\lambda^{T-t-1} G_t}_{\text{完整回报承接剩余权重}} .$$

- n 逐个枚举观察长度； $T - t$ 是从现在到终点还剩的步数。
- 短目标的权重为 $(1 - \lambda)\lambda^{n-1}$ ，所有权重相加等于 1。
- $\lambda = \frac{1}{2}$ 、还剩 3 步时： $\frac{1}{2} + \frac{1}{4} + \frac{1}{4} = 1$ 。

核心理解


这仍是在构造一个学习目标：混合多种预测，而非改变所要估计的策略价值。

资格迹：记录近期访问

到终点获得的新反馈，也可以用于修正多个较早访问过的状态的预测。

资格迹 (Eligibility Trace)

给最近访问过的状态留一个会衰减的“记忆权重”，决定它分担当前 TD 误差的程度。



衰减参数 $\lambda \in [0, 1]$ ；例中 $\gamma = 1$ 、 $\lambda = 0.5$ ，每步旧记忆减半。

核心理解

当前的一个 TD 误差，可以按记忆权重向多个近期状态分配。

累积资格迹与 TD(λ) (选讲)

初始记忆 $e_{-1}(s) = 0$ ；每一步先更新各状态的资格：

$$e_t(s) = \underbrace{\gamma \lambda e_{t-1}(s)}_{\text{过去的记忆逐步衰减}} + \underbrace{1\{S_t = s\}}_{\text{当前访问的状态加 1}} .$$

- $e_t(s)$ 是状态 s 此时的资格； $1\{S_t = s\}$ 成立时为 1，否则为 0。
- 取本步 TD 误差 $\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$ 。

$$V(s) \leftarrow V(s) + \underbrace{\alpha \delta_t e_t(s)}_{\text{同一个误差，按不同记忆权重分配}} .$$

核心理解

每步可以更新多个有资格的状态；新片段开始时清零，非终止返回起点时不清零。

表格型方法中的规划与学习


Planning and Learning with Tabular Methods

一步经验已经能更新价值；借助模型，还能继续利用这一步吗？

直接学习与模型规划

直接学习 (Direct Learning)


真实执行动作，得到 $(S_t, A_t, R_{t+1}, S_{t+1})$ 。



实线：这一步真的发生

规划 (Planning)

查询模型，得到 $(s, a, \hat{r}, \hat{s}')$ 。



虚线：模型给出预测


帽子 $\hat{\cdot}$ 标记模型结果；查询模型时，机器人没有再次移动。

核心理解

规划用模型生成更新材料；价值仍按熟悉的规则更新。

环境模型需要预测什么

给定 (s, a) ，模型预测奖励 $\hat{r}$ 、下一状态 $\hat{s}'$ 和终止标记 $\hat{d} \in \{0, 1\}$ 。



- $\hat{d} = 1$: 已经送达，不再加入后续价值。
- $\hat{d} = 0$: 任务继续；回到办公室，也不等于片段结束。

核心理解

模型 (Model) 回答 “会发生什么”；价值函数 (Value Function) 回答 “长期有多好”。

已知模型与学习模型


已知模型：回顾 DP

直接使用给定规则：

$$p(s', r | s, a).$$

可对所有可能结果求期望。

学得模型：进入 Dyna



$\text{Model}(s, a) \leftarrow (r, s', d)$; 未访问条目仍未知。

适用范围：上图记录针对静态、确定性环境；随机环境需结果分布或采样模型。

核心理解

MC / TD 直接从经验更新价值：无模型（Model-free）；

Dyna 显式利用模型规划：基于模型（Model-based）。

反复用经验：回放与 Dyna 有何区别？

两者都能增加价值更新次数，但提供更新材料的方式不同。

经验回放：取出旧样本

存储真实发生的 (s, a, r, s', d) ，再从缓冲区抽取记录更新 Q 。

无需学习环境模型；本书的表格 Q-learning 也可以回放。

- 额外更新消耗计算，不等于获得更多真实环境观测。
- 简单确定性表格模型可与回放产生相同转移；区别在组织方式及模型用途。

旧经验的策略条件： Q-learning 允许异策略数据；标准同策略 Sarsa 不能不加处理地使用旧策略轨迹。

Dyna：查询学得模型

先学习 $\text{Model}(s, a)$ ，再查询或采样预测结果，更新 Q 。


明确多了一个环节：学习并使用环境模型。

Dyna: 把学习与规划结合起来

Dyna: Integrating Learning and Planning

一次真实经验，既更新价值，也为后续规划补充模型。

Dyna 的学习与规划循环




核心理解

上方直接更新价值；下方先记录环境规律，再通过模拟经验更新价值。

Dyna-Q 的更新目标

对真实或模拟转移 (s, a, r, s', d) , 先构造目标:

$$y = \begin{cases} r, & d = 1 \quad \text{已经终止,} \\ r + \gamma \max_{a'} Q(s', a'), & d = 0 \quad \text{还会继续.} \end{cases}$$



模拟送达: $d = 1$
目标 $y = +10$

$$\underbrace{Q(s, a)}_{\text{当前估计}} \leftarrow Q(s, a) + \alpha \left[\underbrace{y}_{\text{目标}} - Q(s, a) \right].$$


估计对象: $q_*(s, a)$; **所需信息:** 一条转移与终止标记。 a' 遍历下一状态可选动作。

核心理解

Dyna-Q 改变的是经验的**来源**, Q-learning 的目标与误差结构保持不变。

一次模拟经验的数值更新

查询已经学到的模型；设 $\gamma = 1$ 、 $\alpha = 0.5$ 。图中虚线表示模拟结果。



当前动作值
 $Q(O, \text{去 } A) = 4$

当前后续估计
 $\max_{a'} Q(A, a') = 9$

目标 $y = -1 + 9 = 8$,
误差 $y - Q = 8 - 4 = 4$,

新估计 $Q = 4 + 0.5 \times 4 = \boxed{6}$.

这次机器人没有实际移动；模型记录与当前价值估计共同构造目标。

核心理解

转移记录可以重复使用；后续价值在变化，因此目标也可能随之更新。

Dyna-Q 的执行步骤

初始化 Q 、空模型和已观察集合 $\mathcal{D}$ ； n 为每次交互后的规划步数。

1. **行动**：在真实 s 用 ϵ -greedy 选 a ，观察 (r, s', d) 。
2. **直接学习**：计算下方目标 y ，更新 $Q(s, a)$ 。
3. **记模型**： $\text{Model}(s, a) \leftarrow (r, s', d)$ ，把 (s, a) 加入 $\mathcal{D}$ 。
4. **规划 n 次**：从 $\mathcal{D}$ 采样 $(\tilde{s}, \tilde{a})$ ，查询 $(\tilde{r}, \tilde{s}', \tilde{d})$ ，同规则更新 $Q(\tilde{s}, \tilde{a})$ 。
5. **继续**：按真实 s', d 行动；若终止，重新开始送件。波浪号标记模拟数据。

真实交互 1 步

直接更新 1 次

模型规划 20 次

下一次真实交互


$$y = \begin{cases} r, & d = 1, \\ r + \gamma \max_{a'} Q(s', a'), & d = 0, \end{cases} \quad Q(s, a) \leftarrow Q(s, a) + \alpha[y - Q(s, a)].$$

核心理解

规划只更新内部估计，不移动机器人；继续交互仍使用真实的 s', d 。

真实交互与额外计算

每次真实交互后做 $n = 20$ 次规划；100 次真实交互怎样支持 2100 次更新？




- 真实交互仍为 100 次；额外付出的是计算时间。
- 重复查询模型，不会产生新的独立实测证据。

核心理解

有用的规划，让已有信息影响更多价值判断。

规划中的价值传播

更新更多次有什么用？先固定三步路线，只看策略价值 V 的传播：



模型已记录这三步；设 V 初值为 0， $\gamma = \alpha = 1$ ， $V(G) = 0$ 。

$$V(B) \leftarrow 10 + 0 = 10,$$

$$V(A) \leftarrow -1 + 10 = 9,$$

$$V(O) \leftarrow -1 + 9 = 8.$$


核心理解

从后往前备份 (Backup)，让前面的状态“知道”后面能送达。Dyna-Q 对动作价值做类似传播，后续采用最大动作值。

模型误差与环境变化

环境变化：原本可走的 A-B 通道封闭，但模型还保存着旧结果。

旧模型的预测



仍预测下一状态为 B

现在的真实结果



通道封闭，机器人留在 A


- **模型偏差 (Model Bias)**: 模拟结果与真实结果存在系统差异。
- **模型过时 (Stale Model)**: 过去正确的转移记录，现在不再正确。

核心理解

反复使用旧转移，可能高估不可行路线；模型需要真实反馈来检验。

规划与探索的分工

若 A-B 后来重新开放，旧模型仍会说“此路不通”。



- 基本 Dyna-Q 复用已观察的状态与动作；更新过时记录仍要真实尝试。
- **Dyna-Q+**：规划时给很久未尝试的动作增加探索奖励，鼓励重新检查。
- 这是内部探索加项，不是环境真的多发了一笔奖励。

核心理解


Planning 复用信息；Exploration 寻找可能改变判断的新信息。

总结：用学习目标串起本合集

Summary: Connecting Methods Through Learning Targets

从完整回报、一步预测到模拟经验，用“目标从哪里来”串起本合集。

同一个更新骨架，不同的目标来源



方法	学习目标或更新来源	所需信息
DP 评价	$\mathbb{E}_{\pi}[R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s]$	模型与固定策略
MC 预测	完整回报 G_t (可更新 V 或 Q)	完整采样片段
TD(0) 预测	$R_{t+1} + \gamma V(S_{t+1})$	一步真实转移
多步 TD	多个实际奖励，加末端价值估计	一段真实轨迹
Dyna-Q	用真实 / 模拟转移构造 Q-learning 目标	真实经验与学得模型

先辨认目标的两部分

区分实际观测或模型提供的信息，以及尚待学习的价值估计。

预测和控制，要看学什么、怎样用

简写 $R = R_{t+1}$ 、 $S' = S_{t+1}$ 、 $A' = A_{t+1}$ ；终止后自举项为 0。

方法	估计对象	目标	策略如何处理
DP 评价	v_π	$\mathbb{E}_\pi[R + \gamma V(S')]$	固定策略
MC 预测	v_π 或 q_π	G_t	固定策略
TD(0) 预测	v_π	$R + \gamma V(S')$	固定策略
MC 控制	随策略改进的 Q	G_t	改善并探索
Sarsa 控制	跟踪当前策略的 q_π	$R + \gamma Q(S', A')$	改善并探索
Q-learning	q_*	$R + \gamma \max_{a'} Q(S', a')$	行为可含探索

两个关键区分

预测也能学 Q ；Sarsa 固定策略时也能做预测。

控制的关键是改善策略，不能仅凭用了 V 还是 Q 来判断。

强化学习算法的分类维度

维度	类别或表示	本课中的例子
任务	预测 / 控制	策略评估 / 策略迭代
表示	V / Q / 策略	TD(0) / Q-learning / A2C
环境模型	基于模型 / 无模型	DP、Dyna / MC、直接 TD
自举	自举 / 完整回报	TD / MC
策略关系	同策略 / 异策略	标准 Sarsa / Q-learning

Q-learning 的分类

控制；动作值 Q ；无环境模型；自举；允许异策略数据。

学到 Q 后，还需要单独学习 V 吗？

信息关系：要匹配同一个策略

$$v_{\pi}(s) = \sum_a \pi(a | s) q_{\pi}(s, a), \quad v_*(s) = \max_a q_*(s, a).$$

若准确掌握 q_{π} 和 π ，可直接算出 v_{π} ，无需另学一张 V 表。

- **本课无模型控制**：MC Control、Sarsa、Q-learning 直接学 Q ，不依赖先学 V 。
- **本课 DP 控制**：用 V 加环境模型比较动作，逐步改善策略。
- **后续策略梯度**：可直接学习策略，用 V 作为基线或 Critic，帮助评价动作结果。

因此， V 是一种有用的工具，而非所有控制算法的必经步骤

q_* 支持最优决策；它不能直接代入策略平均公式，冒充任意策略的 q_{π} 。

选讲：V 怎样帮助策略变好？

A2C 的分工：策略 π_θ 负责行动，V 估计当前策略表现； $d_t = 1$ 表示终止。

TD 误差：这次行动是否好于原先预期？

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t).$$

若 $V = v_\pi$ ，则 $\mathbb{E}[\delta_t \mid S_t = s, A_t = a] = q_\pi(s, a) - v_\pi(s)$ ，即优势。

更新评估：让预测更准

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t.$$

仍是我们学过的 TD(0)。

$V(S_t)$ 也充当状态基线；不依赖当前动作的基线不改变期望策略梯度。


更新策略：偏向更好的动作

$$\theta \leftarrow \theta + \beta \delta_t \nabla_\theta \log \pi_\theta(A_t \mid S_t).$$

TD 误差提供策略改善信号。


根据可用信息选择方法

1. 已有完整片段




想评价生成片段的固定策略。

2. 希望每步更新



刚走一步，还没有送达。

3. 已学到局部模型




真实交互昂贵，可以查询模型。

- **条件 1:** MC 用完整回报作目标。
- **条件 2:** TD 用一步奖励加后续估计，提前更新。
- **条件 3:** 加入 Dyna 式规划复用模型，并用真实反馈检验它。

核心理解

方法选择可以不唯一，但应说清：手头有什么信息，何时能构造目标。

最终目标是改善策略，价值提供长期判断



本课主线：通过动作值选动作

经验 $\rightarrow$ 更新 Q

$Q \rightarrow$ 贪心或 ϵ -greedy 策略

MC Control、Sarsa、Q-learning、Dyna-Q。

后续路线：直接更新策略

经验 $\rightarrow$ 估计当前策略的长期表现

评价信号 $\rightarrow$ 更新 π_θ

选讲 Actor-Critic：价值负责评价，策略负责行动。

理解一个算法的三个起点

学什么？目标怎么构造？它怎样影响下一次行动？

参考资料

1. 王树森、张志华. 《深度强化学习（初稿）》. 2021。

第 2–5 章与附录 A：概率、MDP、价值、Q-learning、Sarsa 与多步学习。

第 6.1 节、第 8.1/8.3 节：经验回放、价值基线与 Actor-Critic。

2. **Richard S. Sutton and Andrew G. Barto.**

Reinforcement Learning: An Introduction.

第 2 版修订稿 (Second edition, in progress), 2014–2015。

参考主题：Bandit、有限 MDP、动态规划、Monte Carlo、TD、多步方法、资格迹，以及规划与 Dyna。