


01 Tabular RL 学习 Roadmap

苏骏炜 (Junwei Su) 从交互与价值，到策略改进

强化学习以**提高策略的长期期望回报**为目标。箭头表示概念与方法的衔接，学习顺序不意味着运行控制算法前必须先训练一个 V 。



多步方法也可直接扩展 TD 预测；**经验回放**复用真实转移；**选讲衔接**为 V 基线与 Actor-Critic。

读图时分清三组关系

任务	Prediction 固定策略评价 v_π 或 q_π ；Control 改善策略。
表示与路线	V 评价状态， Q 比较动作；价值学习可用于控制，策略学习直接调整策略。
信息与目标	DP 用模型算期望；MC 用完整回报；TD 用采样与自举；Dyna 用模型生成经验。

核心理解 直接学 Q 的控制方法不需要先学 V 。Prediction 提供价值估计的原理； V 与模型结合可用于 DP 控制，也能作为策略学习中的 Critic。

02 交互、回报与策略目标

先说明在优化什么，再说明价值表记录什么

1 表格表示与 Bandit

状态、动作有限且规模可管理时，可按算法需要保存 $V(s)$ 表、 $Q(s, a)$ 表或策略表。不必同时学习 V 和 Q ；表格表示不意味着模型已知或环境确定，相关条目仍需足够访问。

Bandit 每次从 k 个臂中选一个，只观察所选臂的奖励，动作不改变下一轮情境。真实均值 $q_*(a) = \mathbb{E}[R | A = a]$ ，估计为 $Q(a)$ 。第 n 次选臂 a 得到 $R_n^{(a)}$ 后：

$$Q_n(a) = Q_{n-1}(a) + \frac{1}{n} [R_n^{(a)} - Q_{n-1}(a)] = \frac{1}{n} \sum_{i=1}^n R_i^{(a)}.$$

一般更新可用步长 α 代替 $1/n$ 。利用选择当前评分最高的动作，探索尝试其他动作以纠正估计。 ϵ -greedy 以概率 $1 - \epsilon$ 贪心，否则在全部 k 个动作中均匀采样；唯一贪心动作的总概率为 $1 - \epsilon + \epsilon/k$ 。UCB (选讲) 选择 $\arg \max_a [Q_t(a) + c\sqrt{\ln t / N_t(a)}]$ ； $N_t(a)$ 为此前访问次数，此式按 $t \geq 1$ 编号；未尝试的臂先尝试。不确定性加分与环境奖励不同。

2 MDP、策略与随机性

有限 MDP 用状态、动作、转移与奖励规律及折扣因子描述交互。联合模型 $p(s', r | s, a)$ 允许奖励和下一状态随机；策略 $\pi(a | s)$ 给出动作分布。

$$S_t \xrightarrow{A_t} (R_{t+1}, S_{t+1}), \quad \Pr(S_{t+1}, R_{t+1} | H_t, A_t) = \Pr(S_{t+1}, R_{t+1} | S_t, A_t).$$

H_t 是行动前历史。马尔可夫性要求状态保留预测下一步环境结果所需的信息；只看到位置，未必包含电量、任务阶段等必要信息。未来动作还受策略影响。

3 回报、动作价值与状态价值

对终止时刻为 T 的片段，

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1} = R_{t+1} + \gamma G_{t+1}, \quad G_T = 0.$$

奖励是一步反馈，回报是一次轨迹的累计结果； $0 \leq \gamma \leq 1$ 。 $\gamma = 0$ 只重视下一奖励；有界奖励且 $\gamma < 1$ 时无限期回报有界， $\gamma = 1$ 另需保证期望回报有限。

$$\begin{aligned} q_\pi(s, a) &= \mathbb{E}_\pi[G_t | S_t = s, A_t = a] && \text{先做 } a, \text{ 以后按 } \pi \text{ 行动,} \\ v_\pi(s) &= \mathbb{E}_\pi[G_t | S_t = s] = \sum_a \pi(a | s) q_\pi(s, a) && \text{当前动作也按 } \pi \text{ 平均.} \end{aligned}$$

期望平均环境结果与后续动作的随机性。 q_π 仍依赖未来策略；小写 v, q 表示真实期望，大写 V, Q 表示当前估计。
校园送件： $O \xrightarrow{-1} A \xrightarrow{-1} B \xrightarrow{+10} G$ ，进入 G 终止。 $\gamma = 1$ 时三个回报为 8, 9, 10； $V(G) = 0$ 不会删掉送达奖励。单次回报 8 也不自动等于 $v_\pi(O)$ 。

4 最优策略、Prediction 与 Control

固定起始分布 $S_0 \sim d_0$ ，策略目标可写为

$$J(\pi) = \mathbb{E}_{\pi, d_0}[G_0] = \sum_s d_0(s) v_\pi(s), \quad \pi^* \in \arg \max_{\pi} J(\pi).$$

Prediction 固定 π 估计 v_π 或 q_π ；Control 利用经验或模型寻找更好的策略。价值学习与策略学习是**实现路线**，不等同于预测与控制这组**任务划分**。

核心理解 若准确知道 $q_*(s, a) = \max_{\pi} q_\pi(s, a)$ ，直接取 $\pi^*(s) \in \arg \max_a q_*(s, a)$ 即可选最优动作，无须另学 V 。普通估计表 Q 的贪心策略是否最优，取决于估计质量与算法条件。

03 Bellman 与动态规划

MDP 定义问题，Bellman 描述价值关系，DP 利用模型求解

5 一步分解：定义与条件要分开

$G_t = R_{t+1} + \gamma G_{t+1}$ 直接来自回报定义，**不需要马尔可夫性**。在条件期望中用 $v_\pi(S_{t+1})$ 概括未来，则需要状态充分、环境平稳，并配合基于该状态的平稳策略。有限时域若依赖时间，可将时间并入状态或使用 $v_{\pi,t}$ 。

反例：等概率从 A、B 出发，都先到同一观测 X，第一步奖励 0；X 到终点的奖励分别为 +10, -10, $\gamma = 1$ 。只按 X 混合平均得到 $\bar{v}(X) = 0$ ，但

$$\mathbb{E}[G_1 \mid O_0 = A, O_1 = X] = 10 \neq \mathbb{E}[G_1 \mid O_1 = X] = 0.$$

从 A 出发若错误代入 $0 + \bar{v}(X)$ ，就把真实期望 10 算成 0。将状态扩为“位置、起点”，即可区分 (X, A) 与 (X, B) 并正确递推。

6 期望方程与最优方程

固定策略下，既要平均环境后果，也要按策略平均后续动作：

$$v_\pi(s) = \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_\pi(s')],$$

$$q_\pi(s, a) = \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \sum_{a'} \pi(a' \mid s') q_\pi(s', a') \right].$$

最优方程把后续策略选择改为最佳动作：

$$q_*(s, a) = \sum_{s', r} p(s', r \mid s, a) [r + \gamma \max_{a'} q_*(s', a')],$$

$$v_*(s) = \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_*(s')].$$

Bellman 是价值应满足的关系，不等于已经知道价值；模型已知可计算期望，模型未知可从样本构造学习目标。

7 DP：评估与控制更新不同的对象

定义当前状态值表给出的一步动作评分

$$B_V(s, a) = \sum_{s', r} p(s', r \mid s, a) [r + \gamma V(s')].$$

方法	操作	任务
策略评估	固定 π ，迭代 $V_{k+1}(s) = \sum_a \pi(a \mid s) B_{V_k}(s, a)$ 。	Prediction
策略迭代	评估 v_π ，再取 $\pi_{\text{new}}(s) \in \arg \max_a B_{v_\pi}(s, a)$ ，反复交替。	Control
值迭代	反复 $V_{k+1}(s) = \max_a B_{V_k}(s, a)$ ，随后从值表提取贪心策略。	Control

V 的作用：模型把后继状态值转换成每个动作的评分，因此 DP 可用 V 改善策略。GPI（广义策略迭代）允许评价与改进交错进行。有限折扣 MDP 的标准收敛结论不应直接套用到任意未折扣任务。

8 同一三状态模型，对照两种控制过程

在 S 可立即到 G 得 1，或先到 A 得 0；A 的唯一动作到 G 得 3。G 终止， $\gamma = 1$ 。**策略迭代：**初始在 S 立即结束，评估得 $v_\pi(S) = 1, v_\pi(A) = 3$ 。比较 1 与 $0 + 3$ ，改成先去 A，再评估得 $v_{\pi_{\text{new}}}(S) = 3$ 。**同步值迭代：**从全零值表开始， $(V(S), V(A))$ 依次为 $(0, 0) \rightarrow (1, 3) \rightarrow (3, 3)$ 。每轮使用上一轮的值，奖励先到 A，再传播到 S。

核心理解 策略迭代先评价当前策略再改进；值迭代每次就用最优目标备份。二者都属于控制，且都可以用 V 作为中间工具。

04 MC 与 TD：从经验构造价值目标

固定策略先学会评价；改变学习目标或策略，形成不同算法。

9 期望、采样与自举：三个不同的学习目标

固定策略 π ，用 V 估计 v_π 。统一更新为 $X \leftarrow X + \alpha(Y - X)$ ：

方法	预测目标 Y （非终止转移）	信息与机制
DP	$\mathbb{E}_\pi[R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s]$	已知模型；完整期望、自举
MC	G_t	完整片段；采样、不自举
TD(0)	$R_{t+1} + \gamma V(S_{t+1})$	一步经验；采样、自举

广义 Monte Carlo 是用样本平均近似期望；本课的 **MC 方法** 特指用完整回报学习。TD 也采样，但还用当前价值估计自举未来；因此并非这里的 MC 回报方法。


10 MC Prediction 与 Control：四步流程

每个片段内保持当前策略不变；终止后倒推 $G_t = R_{t+1} + \gamma G_{t+1}$ ， $G_T = 0$ 。

步骤	Prediction：评价固定策略	Control：持续改善策略
准备	固定 π ；初始化 V 或 Q	初始化 Q 与探索策略
收集	按固定 π 生成完整片段	按当前策略生成完整片段
学习	算回报，更新选中的 V 或 Q	算回报，更新选中的 Q
继续	保持 π ，重复收集与更新	按 Q 做 ϵ -贪心改进，再收集

固定策略学 Q 仍是 Prediction；MC Control 无需先学 V 。控制中的策略会变化，累计 Q 是持续修正的估计，不是对当前策略已完成的精确评估。

11 首次访问与每次访问：选对回报样本



取 $\gamma = 1$ ：A 的**首次访问**用 $G_1 = 7$ ；**每次访问**用 $G_1 = 7$ 和 $G_3 = 9$ 。回报可倒序计算，“首次”须按正向时间判断；估计 Q 时按 (s, a) 判首次。例如 $V(S_t) \leftarrow V(S_t) + \alpha[G_t - V(S_t)]$ ；估计动作值时换成 $Q(S_t, A_t)$ 。样本平均用 $\alpha = 1/N$ ， N 按当前条目实际选中的样本计数；新片段重置访问记录，**保留值表和累计 N** 。

12 TD(0)：一步真实奖励，加上后继预测

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t), \quad V(S_t) \leftarrow V(S_t) + \alpha \delta_t.$$

例如 O 到 A 得 -1 ， $V(O) = 4$ ， $V(A) = 9$ ，取 $\gamma = 1, \alpha = 0.5$ ：目标 $Y = 8$ ，于是 $V(O) \leftarrow 4 + 0.5(8 - 4) = 6$ 。**真正终止**： $Y = R_{t+1}$ ；坠崖得 -100 后回起点继续，仍需自举；人为时间截断不自动等于终止。TD 用一步样本近似 Bellman 备份，再用当前估计补上未来，单次目标不保证更准确。固定 π 、完整回报可积时，MC 目标的条件期望等于真值；TD 会传递后继估计的偏差。目标方差没有普遍大小顺序，**目标无偏也不保证任意训练结果无偏**。

05 控制与多步学习：目标决定后续行为

动作值可用于预测或控制；多步目标与资格迹延伸信用分配的范围。

13 Sarsa 与 Q-learning：未来按谁的行为评价

行为策略 b 产生经验，**目标策略** π 是被评价或改善的策略。On-policy 使用同一策略；Off-policy 允许两者不同，也可在线学习，仍需数据覆盖。

方法	非终止时的目标 Y_t	估计对象与行为
Sarsa	$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$	评价当前 π ；同策略
Q-learning	$R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a')$	学习 q_* ；允许异策略

均更新 $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[Y_t - Q(S_t, A_t)]$ 。标准在线 Sarsa 先按行为策略选 A_{t+1} ，构造目标并更新，随后执行**同一个动作**；Q-learning 的目标不需要实际下一动作。真正终止时均取 $Y_t = R_{t+1}$ 。**同一经验**：旧 $Q(O, \text{去 } A) = 5$ ，本步奖励 -1 ， $\gamma = 1, \alpha = 0.5$ ； A 中最大动作值为 9，探索实际选中值为 2 的动作：

$$\text{Sarsa: } Y = -1 + 2 = 1, \quad Q \leftarrow 5 + 0.5(1 - 5) = 3;$$

$$\text{Q-learning: } Y = -1 + 9 = 8, \quad Q \leftarrow 5 + 0.5(8 - 5) = 6.5.$$

Sarsa 固定 π 时预测 q_π ，控制时随 Q 改善策略。**固定** $\epsilon > 0$ 的悬崖行走中，它会计入未来探索的代价，可能偏好较远路线；两算法不必产生不同路线。

14 多步目标：既能更新 V ，也能直接更新 Q

固定策略下，若 $t + n < T$ ：

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n V(S_{t+n}),$$

$$G_{t,Q}^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n Q(S_{t+n}, A_{t+n}).$$

第二式为多步 Sarsa：途中及末端动作均按同一 π 采样。若 $t + n \geq T$ ，只累加到终点，目标为 G_t ，不再自举；**末尾不足 n 步的样本也要更新**。

15 选讲： λ -回报与累积资格迹

令 $L = T - t$ ，有限片段的前向目标为

$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{L-1} \lambda^{n-1} G_t^{(n)} + \lambda^{L-1} G_t.$$

$\lambda = 0$ 取一步目标， $\lambda = 1$ 取完整回报；剩 3 步且 $\lambda = 0.5$ 时权重为 0.5, 0.25, 0.25。后向累积迹使用同一个 TD 误差更新多个状态：

$$e_t(s) = \gamma \lambda e_{t-1}(s) + \mathbf{1}\{S_t = s\}, \quad V(s) \leftarrow V(s) + \alpha \delta_t e_t(s).$$

新片段清零迹；未终止返回起点不清零。**普通在线 TD(1) 不因此与 MC 完全相同**；在线更新会改变后继估计，前后向等价须说明相应条件或算法。

16 最优性保证：访问、步长与策略缺一不可

标准折扣表格设置：状态动作有限、奖励有界、 $0 \leq \gamma < 1$ ，每个 (s, a) 无限次访问。按**该条目第 n 次更新**选正步长，满足

$$\sum_{n=1}^{\infty} \alpha_n(s, a) = \infty, \quad \sum_{n=1}^{\infty} \alpha_n^2(s, a) < \infty.$$

Q-learning 可在这些条件下收敛到 q_* ；Sarsa 控制还需**无限探索、极限贪心 (GLIE)**。固定正 ϵ 的行为本身通常非最优；固定步长有噪声时通常持续波动， $\gamma = 1$ 需另加适当终止条件。

06 复用经验、模型规划与价值的用途

同一条更新规则，可以使用不同来源的信息；价值服务于策略改善。

17 经验回放与 Dyna：更新材料的来源

方法	更新材料的来源
经验回放	从缓冲区抽取保存的真实转移；无需环境模型。
Dyna	查询学得模型，产生模拟转移；真实反馈继续校准模型。

Q-learning 可用异策略数据；重放旧策略的 Sarsa 五元组通常需要额外处理。额外更新不增加真实观测；随机回放只能减弱时间相关性。简单确定性模型可能返回与回放相同的转移。

18 Dyna-Q：真实学习、模型学习与规划



对真实或模拟的 (s, a, r, s', d) ，使用相同目标与更新； $d = 1$ 表示真正终止：

$$y = \begin{cases} r, & d = 1, \\ r + \gamma \max_{a'} Q(s', a'), & d = 0, \end{cases} \quad Q(s, a) \leftarrow Q(s, a) + \alpha[y - Q(s, a)].$$

确定性模型可记录 (r, s', d) ；随机环境需结果分布或采样模型。模型错误或过时，规划也会传播错误；更多计算不能替代真实探索。反复使用有限旧数据，并不自动保证收敛到真实环境的 q_* 。收敛仍需访问覆盖、合适步长与任务条件；规划次数不是收敛保证。

19 V 是工具，不是所有控制算法的必经步骤

DP: V 配合已知模型计算各动作后果，再改善策略。**直接学 Q :** MC Control、Sarsa、Q-learning 无需先学习 V ；已知准确 q_π 与 π 可直接算出 v_π 。**V-Critic (选讲):** 策略负责行动， V 评价当前策略；动作通过奖励和下一状态进入 TD 误差：

$$\delta_t = R_{t+1} + \gamma(1 - d_t)V(S_{t+1}) - V(S_t), \quad \mathbb{E}[\delta_t | s, a]_{V=v_\pi} = q_\pi(s, a) - v_\pi(s).$$

当 $V = v_\pi$ 时，上式期望等于优势；实际使用估计 V 时，TD 误差只是优势的近似信号。 $V(s)$ 也可作状态基线：不依赖当前动作的基线不改变期望策略梯度，合适的基线可降低方差。

20 书本与本笔记的记号对照

中文教材	本笔记	含义
R_t, U_t	R_{t+1}, G_t	当前动作的反馈、后续回报
Q_π, V_π	q_π, v_π	真实价值；本笔记的 Q, V 为估计
误差：预测减目标	误差：目标减预测	更新符号相反，实际修正相同

参考资料

苏骏炜. 《表格型强化学习》当前 120 页课件，Lecture 1 与 Lecture 2 合集。

王树森、张志华. 《深度强化学习（初稿）》. 2021。主要参考第 2-5 章、附录 A，以及第 6.1、8.1、8.3、11.1 节。

Sutton, R. S., & Barto, A. G. *Reinforcement Learning: An Introduction*. 第 2 版修订稿 (2014-2015)。表格方法见第 2-8 章；资格迹为第 7 章，规划与 Dyna 为第 8 章。